



Рубежный контроль №1 (весна 2026)

Студент: Королев А.С.

Группа: ИУ5Ц-81Б

Вариант: 26 (Задача №4, набор №2 - Wine)

Доп. требование (ИУ5Ц-81Б): Диаграмма рассеяния

Импорт и проверка

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_wine

# Проверка версий
print(f"Pandas: {pd.__version__}")
print(f"Seaborn: {sns.__version__}")

# Настройка графиков
%matplotlib inline
sns.set_theme(style="whitegrid")
```

Pandas: 3.0.2

Seaborn: 0.13.2

Загрузка данных

```
In [2]: # Загрузка датасета Wine
data = load_wine()
df = pd.DataFrame(data.data, columns=data.feature_names)
df['target'] = data.target

print(f"Размер данных: {df.shape}")
print(f"\nПропуски: \n{df.isnull().sum()}")
df.head()
```

Размер данных: (178, 14)

```
Пропуски:
alcohol      0
malic_acid   0
ash          0
alcalinity_of_ash  0
magnesium    0
total_phenols 0
flavanoids   0
nonflavanoid_phenols 0
proanthocyanins 0
color_intensity 0
hue          0
od280/od315_of_diluted_wines 0
proline      0
target       0
dtype: int64
```

```
Out[2]:
```

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids
0	14.23	1.71	2.43	15.6	127.0	2.80	0.56
1	13.20	1.78	2.14	11.2	100.0	2.65	0.54
2	13.16	2.36	2.67	18.6	101.0	2.80	0.61
3	14.37	1.95	2.50	16.8	113.0	3.85	0.74
4	13.24	2.59	2.87	21.0	118.0	2.80	0.62

Обработка пропусков

```
In [3]: # =====
# ИСКУССТВЕННОЕ СОЗДАНИЕ ДАННЫХ (по требованию Примечаний)
# =====

print("="*60)
print("СОЗДАНИЕ ИСКУССТВЕННЫХ ДАННЫХ (по требованию Примечаний)")
print("="*60)

# 1. Создаём категориальный признак на основе числового
df['alcohol_category'] = pd.cut(df['alcohol'],
                                bins=[0, 12, 13.5, 20],
                                labels=[1, 2, 3])
print("\n1. Создан категориальный признак 'alcohol_category' на основе 'alcohol'")
print(df['alcohol_category'].value_counts())

# 2. Создаём пропуски в числовом признаке (10%)
np.random.seed(42)
mask = np.random.random(len(df)) < 0.1
df.loc[mask, 'malic_acid'] = np.nan
```

```

print(f"\n2. Созданы пропуски в 'malic_acid': {df['malic_acid'].isnull().sum()}

# 3. Создаём пропуски в категориальном признаке (5%)
mask_cat = np.random.random(len(df)) < 0.05
df.loc[mask_cat, 'alcohol_category'] = np.nan

print(f"\n3. Созданы пропуски в 'alcohol_category': {df['alcohol_category'].isnull().sum()}

print("\nИскусственные данные созданы.")

```

=====

СОЗДАНИЕ ИСКУССТВЕННЫХ ДАННЫХ (по требованию Примечаний)

=====

1. Создан категориальный признак 'alcohol_category' на основе 'alcohol':

```
alcohol_category
```

```
2    101
```

```
3     55
```

```
1     22
```

```
Name: count, dtype: int64
```

2. Созданы пропуски в 'malic_acid': 21 шт. (11.8%)

3. Созданы пропуски в 'alcohol_category': 12 шт. (6.7%)

Искусственные данные созданы.

```

In [4]: print("="*60)
        print("ОБРАБОТКА ПРОПУСКОВ (по требованию ТЗ)")
        print("="*60)

        print(f"Размер ДО удаления: {df.shape}")
        print(f"Пропуски:\n{df.isnull().sum()}")

        # Удаляем строки с пропусками
        df_cleaned = df.dropna()

        print(f"\nРазмер ПОСЛЕ удаления: {df_cleaned.shape}")
        print(f"Удалено строк: {df.shape[0] - df_cleaned.shape[0]}")

        df = df_cleaned
        print("\n Данные очищены, можно строить графики.")

```

=====

ОБРАБОТКА ПРОПУСКОВ (по требованию ТЗ)

=====

Размер ДО удаления: (178, 15)

Пропуски:

alcohol	0
malic_acid	21
ash	0
alcalinity_of_ash	0
magnesium	0
total_phenols	0
flavanoids	0
nonflavanoid_phenols	0
proanthocyanins	0
color_intensity	0
hue	0
od280/od315_of_diluted_wines	0
proline	0
target	0
alcohol_category	12
dtype: int64	

Размер ПОСЛЕ удаления: (145, 15)

Удалено строк: 33

Данные очищены, можно строить графики.

график 1: гистограммы

```
In [5]: fig, axes = plt.subplots(4, 4, figsize=(14, 10))
        axes = axes.flatten()

        for i, col in enumerate(df.columns[:-1]): # кроме target
            sns.histplot(df[col], kde=True, ax=axes[i])
            axes[i].set_title(col, fontsize=8)
            axes[i].set_xlabel('')

        plt.suptitle('Распределение признаков', fontsize=14)
        plt.tight_layout()
        plt.show()
```




график 2: ящики с усами (boxplot)

```
In [6]: plt.figure(figsize=(14, 6))
df_melt = df.melt(id_vars=['target'], var_name='feature', value_name='value')
sns.boxplot(x='feature', y='value', data=df_melt)
plt.xticks(rotation=45, ha='right')
plt.title('Ящик с усами (boxplot) для всех признаков')
plt.tight_layout()
plt.show()
```




график 3: тепловая карта корреляций

```
In [7]: plt.figure(figsize=(12, 8))
corr = df.drop('target', axis=1).corr()
sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdYlBu_r', center=0)
plt.title('Корреляционная матрица')
plt.tight_layout()
plt.show()
```





график 4 (требование к группе):
диаграмма рассеяния

```
In [8]: plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='flavanoids', y='total_phenols', hue='target',
                palette='Set1', s=80, alpha=0.7)
plt.title('Диаграмма рассеяния: Flavanoids vs Total Phenols')
plt.tight_layout()
plt.show()
```



Выводы

```
In [9]: print("="*70)
print("ВЫВОДЫ ПО ЗАДАЧЕ №4 (РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ)")
print("="*70)

# 1. Данные после очистки
print(f"""
1. ОБРАБОТКА ДАННЫХ:
- Исходный размер Wine dataset: 178 строк, 13 признаков + target
- Созданы искусственные пропуски (10% в malic_acid, 5% в alcohol_category)
- После удаления строк с пропусками осталось: {df.shape[0]} строк, {df.shape[1]} признаков
- Удалено строк: {178 - df.shape[0]} ({((178 - df.shape[0])/178)*100:.1f}%)
""")

# 2. Корреляционный анализ
corr_matrix = df.drop('target', axis=1).corr()
# Находим максимальную корреляцию (не считая диагональ)
max_corr = -1
max_pair = ("", "")
for i in range(len(corr_matrix.columns)):
    for j in range(i+1, len(corr_matrix.columns)):
        if abs(corr_matrix.iloc[i, j]) > max_corr:
            max_corr = abs(corr_matrix.iloc[i, j])
            max_pair = (corr_matrix.columns[i], corr_matrix.columns[j])

print(f"""
2. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ:
- Максимальная корреляция между признаками: {max_pair[0]} ↔ {max_pair[1]} = {max_corr:.2f}
""")
```

```

- Вывод: Высокая корреляция указывает на мультиколлинеарность,
  при построении линейных моделей один из этих признаков можно исключить.
""")

# 3. Анализ выбросов (по IQR)
outlier_info = ""
for col in ['malic_acid', 'proline']:
    if col in df.columns:
        Q1 = df[col].quantile(0.25)
        Q3 = df[col].quantile(0.75)
        IQR = Q3 - Q1
        outliers = df[(df[col] < Q1 - 1.5*IQR) | (df[col] > Q3 + 1.5*IQR)].shape[0]
        outlier_info += f"    • {col}: {outliers} выбросов ({outliers/len(df)}%)"

print(f"""
3. АНАЛИЗ ВЫБРОСОВ (по boxplot):
{outlier_info}
""")

# 4. Анализ диаграммы рассеяния
# Получаем средние значения flavanoids и total_phenols по классам
means = df.groupby('target')[['flavanoids', 'total_phenols']].mean()
print(f"""
4. ДИАГРАММА РАССЕЯНИЯ (flavanoids vs total_phenols) - требование группы ИУ5Ц-
- Средние значения по сортам вина:
    • Класс 0: flavanoids = {means.loc[0, 'flavanoids']:.2f}, total_phenols = {means.loc[0, 'total_phenols']:.2f}
    • Класс 1: flavanoids = {means.loc[1, 'flavanoids']:.2f}, total_phenols = {means.loc[1, 'total_phenols']:.2f}
    • Класс 2: flavanoids = {means.loc[2, 'flavanoids']:.2f}, total_phenols = {means.loc[2, 'total_phenols']:.2f}
- Вывод: Признаки flavanoids и total_phenols хорошо разделяют классы вин,
  особенно класс 0 (высокие значения) и класс 2 (низкие значения).
""")

# 5. Общий вывод
print(f"""
5. ОБЩИЙ ВЫВОД:
- Датасет пригоден для построения моделей машинного обучения.
- Целевая переменная (сорт вина) имеет 3 класса.
- Рекомендуемые признаки для модели: flavanoids, total_phenols, proline, осадок.
- Рекомендуемая предобработка: масштабирование (StandardScaler).
""")

```

=====

ВЫВОДЫ ПО ЗАДАЧЕ №4 (РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ)

=====

1. ОБРАБОТКА ДАННЫХ:

- Исходный размер Wine dataset: 178 строк, 13 признаков + target
- Созданы искусственные пропуски (10% в malic_acid, 5% в alcohol_category)
- После удаления строк с пропусками осталось: 145 строк, 15 столбцов
- Удалено строк: 33 (18.5%)

2. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ:

- Максимальная корреляция между признаками: alcohol ↔ alcohol_category = 0.880
- Вывод: Высокая корреляция указывает на мультиколлинеарность, при построении линейных моделей один из этих признаков можно исключить.

3. АНАЛИЗ ВЫБРОСОВ (по boxplot):

- malic_acid: 2 выбросов (1.4%)
- proline: 0 выбросов (0.0%)

4. ДИАГРАММА РАССЕЯНИЯ (flavanoids vs total_phenols) - требование группы ИУ5Ц-815:

- Средние значения по сортам вина:
 - Класс 0: flavanoids = 3.00, total_phenols = 2.84
 - Класс 1: flavanoids = 2.08, total_phenols = 2.26
 - Класс 2: flavanoids = 0.81, total_phenols = 1.68
- Вывод: Признаки flavanoids и total_phenols хорошо разделяют классы вин, особенно класс 0 (высокие значения) и класс 2 (низкие значения).

5. ОБЩИЙ ВЫВОД:

- Датасет пригоден для построения моделей машинного обучения.
- Целевая переменная (сорт вина) имеет 3 класса.
- Рекомендуемые признаки для модели: flavanoids, total_phenols, proline, od280/od315.
- Рекомендуемая предобработка: масштабирование (StandardScaler).